Defiende el servidor

Taller evaluable · Versionado de código, datos, experimentos y modelos · MLOps 2026-II · Universidad Externado de Colombia

Integrantes y grupo: PENDIENTE · **Fecha:** octubre de 2026

Código: github.com/Jhaycoltez512/Taller_MLOps · **Datos (DVC):** dagshub.com/Jhaycoltez512/Taller_MLOps · **Modelos:** huggingface.co/yeico512/unsw-nb15-defiende-el-servidor

> **Pregunta central.** Si se pierde la carpeta de trabajo, ¿se puede recuperar una versión concreta, explicar de qué datos y experimento viene y usarla para predecir? **Sí:** en una carpeta y un entorno nuevos se recuperaron los datos desde DagsHub con sus huellas y las versiones v1 y v2 desde Hugging Face por SHA, y sus predicciones coincidieron con las guardadas (sección 7).

1 Datos, auditoría y limpieza

Se usan los splits publicados de UNSW-NB15: `UNSW_NB15_training-set.csv` (175.341 filas) y `UNSW_NB15_testing-set.csv` (82.332 filas), ambos con 45 columnas, descargados el 23-10-2026 de la fuente oficial de UNSW. Sus SHA-256 coinciden con las huellas del anexo del enunciado y se versionan con DVC (`data/original.dvc`). El objetivo es `label` (1 = ataque, clase positiva); se excluyen de las entradas `id` (identifica la fila), `attack_cat` (revela la respuesta) y `label`. Quedan 42 entradas, 3 categóricas (`proto`, `service`, `state`).

Hallazgo de la auditoría	Entrenamiento	Test	Política
Faltantes	0	0	—
% de ataques	68,1 %	55,1 %	Se reporta; métricas por clase, no accuracy
Filas que repiten un vector de entradas	74.301 (42,4 %)	28.386 (34,5 %)	Se conservan y se agrupan por vector (`group_id`)
Grupos con `label` 0 y 1 a la vez	229 (940 filas)	6 (14 filas)	Se excluyen de train/val; test completo
`is_ftp_login` > 1 (variable binaria)	22	4	Se acota a {0, 1} en todas las particiones
Valores de `state` solo en test	—	ACC, CLO	El codificador ignora o agrupa valores no vistos

Particiones. Train y validación salen solo del archivo de entrenamiento, con `StratifiedGroupKFold` (5 folds, estratificado por `attack_cat`, semilla 42; el fold 0 es validación): 139.520 y 34.881 filas, ambas con 68,1 % de ataques. **Ningún vector de entradas aparece a la vez en train y validación.** Se conservan los duplicados porque el test tampoco está deduplicado y así la validación refleja la misma distribución; agruparlos impide la fuga. El test se reserva completo. El 8,1 % de sus filas (6.646) comparte vector con train y el 2,0 % con validación: se reporta y no se eliminan filas. La limpieza es determinista y sin estado; codificación y escalado viven dentro del `Pipeline` de cada modelo y se ajustan solo con train. Los datos preparados (`data/prepared`, `dvc.lock`) son la segunda versión de datos; ambas están en DagsHub y la auditoría completa en `evidencias/auditoria.json`.

2 Cuatro experimentos

Cuatro configuraciones de dos familias, con las mismas particiones, semilla 42 y regla de umbral. Cada run de MLflow registra hipótesis, cambio, parámetros, commit Git (`fecc329`, árbol limpio), versión DVC, métricas de validación y el modelo completo (formato skops, con su SHA-256). La exportación está en `evidencias/mlflow/` y la tabla en `evidencias/experimentos.csv`.

ID	Hipótesis y cambio	Umbral	Recall	Precision	FPR	Macro-F1	FPR @0,5
exp01	Referencia lineal: regresión logística, one-hot + estandarización	0,773	0,896	0,972	5,4 %	0,902	18,0 %
exp02	Variables muy asimétricas: + `log1p` antes de estandarizar	0,774	0,913	0,975	5,1 %	0,916	13,7 %

exp03	Interacciones no lineales: Random Forest (150 árboles), categóricas ordinales	0,648	0,953	0,976	5,1 %	0,945	9,6 %
exp04	**Boosting más compacto: HistGradientBoosting con categóricas nativas**	**0,639**	**0,956**	**0,976**	**5,0 %**	**0,948**	**8,6 %**

Métricas de validación (34.881 filas) con ataque como positivo. Si una razón tiene denominador cero vale 0 y queda marcada; no ocurrió. FPR @0,5: con el umbral por defecto.

Interpretación. Las hipótesis se confirmaron; la de exp01, en parte: es una base razonable, pero con más errores que los árboles. `log1p` mejoró al modelo lineal (+1,8 pp de recall con igual FPR), pero el mayor salto fue cambiar de familia (+4 pp más con árboles). HistGradientBoosting iguala al Random Forest con un artefacto de 2,2 MB frente a 52 MB y se entrena en 3 s. Por categoría (figura 1), los errores se concentran en **Fuzzers**: los modelos lineales detectan el 55 % y los de árboles el 72–74 %; `Analysis` queda cerca del 85 % en todos. Con el umbral de 0,5, todos los modelos tendrían una FPR de entre 8,6 % y 18 %; por eso el umbral se elige explícitamente.

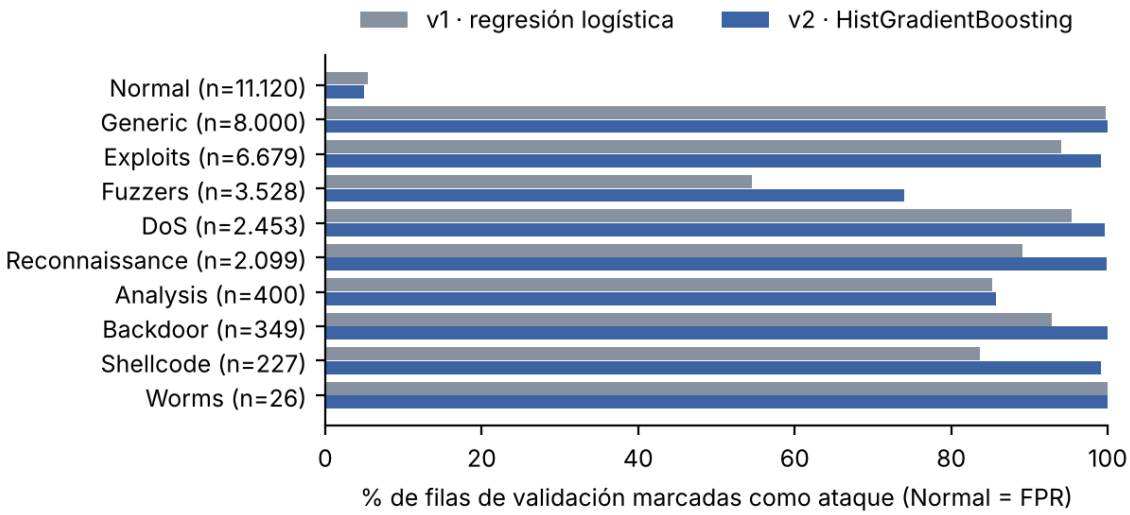


Figura 1. Porcentaje de filas de validación marcadas como ataque por categoría (para Normal es la FPR). Fuente: `evidencias/errores_por_categoria.csv`.

3 Elección del umbral

El equipo de seguridad tolera un número limitado de alertas sobre tráfico normal. La regla, fijada antes de entrenar (`params.yaml`): **máximo recall de ataque con FPR ≤ 5 %**, sobre una rejilla de paso 0,001; ataque si `score_attack ≥ umbral`. Para no gastar la validación, el umbral se elige con **predicciones out-of-fold sobre train** (5 folds agrupados con los mismos grupos que el split). La validación queda limpia para comparar modelos y confirma que el umbral se traslada: la FPR resultante está entre 5,0 % y 5,4 %.

4 Versiones v1 y v2

v1 es la primera solución funcional: exp01 (regresión logística, umbral 0,773). **v2** se eligió solo con validación, con la regla de `configs/seleccion.yaml`: mayor recall entre las configuraciones con FPR de validación ≤ 5,5 % (el 5 % objetivo más media unidad de tolerancia, porque el umbral se fijó en OOF). Ganó exp04. La decisión se guardó en `evidencias/seleccion.json` y quedó congelada en el commit `adcd955`, antes de leer el test.

Validación	v1 (exp01)	v2 (exp04)	Cambio
Recall de ataque	0,896	0,956	+6,0 pp
Precision de ataque	0,972	0,976	+0,4 pp
FPR	5,44 %	4,99 %	−0,45 pp
Macro-F1	0,902	0,948	+4,6 pp
Falsos negativos / falsos positivos	2.483 / 605	1.045 / 555	−1.438 / −50

Qué cambia: el modelo (regresión logística → HistGradientBoosting), en consecuencia el preprocesamiento (one-hot + estandarización → ordinal) y el umbral (0,773 → 0,639); la regla del umbral es la misma. **Qué mejora:** los falsos negativos caen a menos de la mitad, sobre todo en Fuzzers (55 % → 74 %), Shellcode y Reconnaissance, con menor FPR. **Qué empeora:** v2 es menos interpretable (sin coeficientes por variable) y pesa 2,2 MB frente a 0,3 MB. **Errores aceptados:** ~5 % de conexiones normales marcadas y ~26 % de Fuzzers sin detectar.

Ambas versiones están en Hugging Face con model card, configuración y umbral, dependencias fijadas y referencias a Git, DVC y MLflow:

	Revisión de Hugging Face (SHA completo)	Run de MLflow	SHA-256 del modelo
v1	`896ee3984613e60d2af1c5297163524216fec34b`	`b1c856bd…`	`feb7d024…1771`
v2	`424eef599abdce7630cfc369505487755b9763f4`	`98001a52…`	`562ba1bc…489c`

---

5 Evaluación final en test

La v2 congelada se descargó de Hugging Face por su SHA (con el hash del modelo y el umbral verificados) y se evaluó una sola vez sobre las 82.332 filas del test, sin eliminar ninguna. Las predicciones por fila están en `evidencias/predicciones-test.csv` y las métricas en `evidencias/metricas-test.json`; recalculadas con scikit-learn desde el CSV, coinciden exactamente.

Métrica	Validación	Test
Recall de ataque	0,956	0,968
Precision de ataque	0,976	0,867
FPR	5,0 %	**18,2 %**
Macro-F1	0,948	0,898
ROC-AUC	0,994	0,983

Test	Predice normal	Predice ataque
Normal (37.000)	30.261	6.739
Ataque (45.332)	1.454	43.878

El resultado empeora en FPR y se conserva. La capacidad de ordenar casi no cambia (ROC-AUC 0,983), pero con el umbral congelado la FPR pasa de 5 % a 18,2 %. El análisis posterior (`evidencias/analisis-test.json`) lo explica: en test, el **51,8 % del tráfico normal** tiene `sttl` 62 o 254, valores típicos de los equipos atacantes del banco de pruebas, frente al 23 % en train y validación. **Los 6.739 falsos positivos están en ese grupo**; fuera de él la FPR es 0,0 %. El modelo aprendió un artefacto de la topología del laboratorio (el TTL) y el test tiene otra distribución de tráfico normal. El solapamiento con train no lo explica: las filas no vistas tienen la misma FPR (18,2 %). No se ajustaron modelo ni umbral después de ver estos resultados.

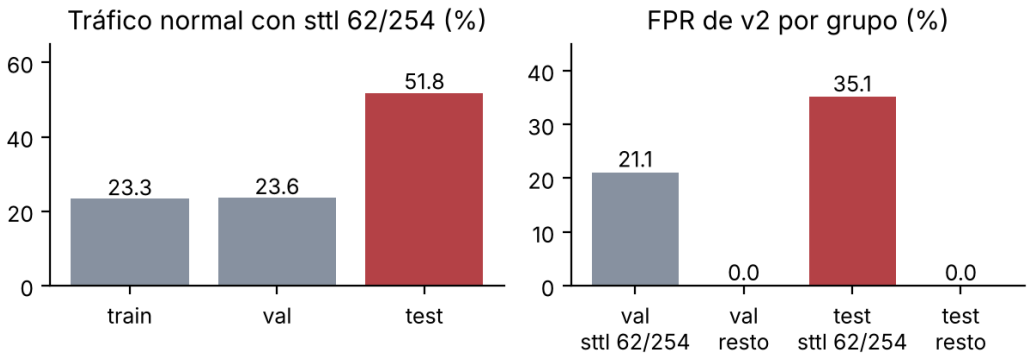


Figura 2. Izquierda: tráfico normal con sttl 62/254 por partición. Derecha: FPR de v2 dentro y fuera de ese grupo. Fuente: `evidencias/analisis-test.json`.

6 Qué versiona cada herramienta

Herramienta	Qué versiona en este proyecto
Git + GitHub	Código, configuraciones, parámetros, referencias DVC y evidencias; v1 en el commit `b15a8b2` y v2 en `adcd955`; ambos modelos se entrenaron con el código de `fecc329`.
DVC + DagsHub	Datos originales (`23b017bf…dir`) y preparados con sus particiones (`e2f660e3…dir`), recuperables con `dvc pull` sin la caché original.
MLflow	Cuatro runs con hipótesis, parámetros, commit, versión DVC, métricas y modelo; exportados para consultarlos sin servidor.
Hugging Face Hub	Dos revisiones completas, identificadas por SHA y tag, con model card que cita commit, versión DVC y run.

Cadena: **commit Git** `fecc329` → **datos DVC** `e2f660e3…dir` → **run** `98001a52…` → **revisión HF** `424eef59…`, unidos por el SHA-256 del modelo `562ba1bc…`: el modelo descrito, el descargado y el que produjo las predicciones de test son el mismo archivo.

7 Prueba de recuperación

Con `scripts/recuperacion.sh`, en una carpeta y un entorno nuevos y sin cachés: clon del commit `91f71a2` desde GitHub; instalación del lockfile sin caché (298 s); `dvc pull` desde DagsHub con caché vacía (10 s; SHA-256 iguales al anexo y a la auditoría); descarga de v1 y v2 por SHA completo sin token, en una caché vacía; predicción sobre 30 filas fijas de validación (3 por categoría, semilla 42). Comparadas con las salidas guardadas por los runs originales: **mismas etiquetas y diferencia máxima de probabilidad de $1{,}1 \cdot 10^{-16}$** en ambas versiones (tolerancia declarada 10^{-9}). Total: 327 s. Log, entradas, salidas y hashes en `evidencias/recuperacion/`. Además, reentrenar exp04 en un clon aparte reprodujo las mismas métricas y predicciones.

8 Limitaciones

- UNSW-NB15 es un dataset sintético de 2015: estos resultados no demuestran eficacia sobre una red actual.
- El modelo depende del TTL, un artefacto del banco de pruebas. Una revisión futura debería probar a excluir `sttl`, `dttl` y `ct_state_ttl` o recalibrar el umbral con tráfico normal reciente; no se hizo aquí para no usar el test en decisiones.
- El umbral fija la FPR sobre la distribución de entrenamiento; si cambia el tráfico normal, la FPR cambia (como en test).
- Fuzzers sigue siendo la categoría peor detectada; las categorías pequeñas (Worms: 26 filas en validación) tienen estimaciones inestables.
- El seguimiento de MLflow fue local; la evidencia consultable es la exportación en el repositorio.

Uso de IA. Se usó Claude Code (Anthropic) para escribir el código, la documentación y el análisis. Las cifras de este informe provienen de los archivos de `evidencias/` y se verificaron con recálculos independientes. Contribuciones de

cada integrante: ver `entrega.md`.

Referencias

- Moustafa, N. y Slay, J. (2015). UNSW-NB15: a comprehensive data set for network intrusion detection systems. *MilCIS 2015*, IEEE.
- UNSW Canberra. The UNSW-NB15 Dataset. https://research.unsw.edu.au/projects/unsw-nb15-dataset
- Documentación de DVC (dvc.org), MLflow Tracking (mlflow.org), Hugging Face Hub (huggingface.co/docs/hub) y scikit-learn (scikit-learn.org).